



SEMANA 3

DADOS COM PANDAS

Analizando o mundo real com Python

Datasets reais + Pandas + Matplotlib + Ecossistema — tudo via Vibe Coding



O Que São Dados? (E Por Que Importam)

Tudo é dado. Planilhas de vendas, logs de servidor, posts de rede social, sensores IoT, registros de ataques cibernéticos...

Quem sabe ler e transformar dados em informação útil tem superpoder no mercado.

Tipos de dados:

Estruturados

Tabelas, planilhas, CSV, bancos de dados. Linhas e colunas organizadas.

Planilha de clientes, logs de firewall

Semi-estruturados

JSON, XML, APIs. Alguma estrutura mais flexível.

Respostas de API, dados de IoT

Não-estruturados

Texto livre, imagens, áudio, vídeo. Sem formato fixo.

Emails, PDFs, capturas de tela



Datasets: De Onde Vem os Dados?

Dataset = conjunto de dados organizado, pronto pra analise. Existem milhares de graça!

Kaggle

kaggle.com/datasets

Logs de ataques, dados COVID, precos de casas

A maior plataforma de datasets do mundo. Milhares gratuitos.

dados.gov.br

dados.gov.br

Criminalidade, educacao, saude publica

Portal de dados abertos do governo brasileiro. Dados oficiais.

GitHub Awesome github.com/awesomedata

Redes sociais, clima, seguranca

Colecao curada de datasets organizados por tema.

APIs publicas

(VirusTotal, Shodan...)

Threat intel, clima, cambio

Serviços que oferecem dados via API em tempo real.



Pandas: Sua Ferramenta de Dados

Pandas é uma biblioteca Python para trabalhar com dados em formato de tabela.

Pense nele como um Excel superpotente dentro do Python. Carrega um arquivo, filtra, agrupa, calcula, tudo com poucas linhas (que a IA escrever para você!).

Conceitos-chave:



DataFrame

A tabela. Linhas = registros, colunas = informações.



Series

Uma única coluna. Ex: só a coluna "idade".



CSV

Arquivo texto com dados separados por vírgula. Formato mais comum.



Index

Número da linha. Começa do 0.



Matplotlib: Transformando Dados em Graficos

Matplotlib e a biblioteca padrão do Python para criar gráficos e visualizações.

Se Pandas e o Excel dos dados, Matplotlib e o PowerPoint dos graficos. Você transforma tabelas em barras, linhas, pizzas, dispersão, qualquer tipo de gráfico profissional.

O que da pra fazer:

Barras

kind="bar"

Comparar valores entre categorias. Ex: ataques por pais.

Linhas

kind="line"

Mostrar tendências ao longo do tempo. Ex: ataques por mes.

Pizza

kind="pie"

Mostrar proporcoes. Ex: tipos de ataque em %.

Histograma

kind="hist"

Distribuicao de valores. Ex: duracao dos ataques.



O Ecossistema de Dados em Python

Pandas e Matplotlib sao a base, mas existe um universo de bibliotecas que complementam:

NumPy

CALCULO

A base matematica. Operacoes com arrays, matrizes, algebra linear. Pandas usa NumPy por baixo.

Cálculos pesados, estatística

Seaborn

VISUAL

Gráficos estatísticos bonitos com poucas linhas. Construído em cima do Matplotlib, mas mais elegante.

Heatmaps, distribuicoes, correlates

Plotly

INTERATIVO

Graficos interativos — zoom, hover, filtros. Perfeito para dashboards e apresentações web.

Dashboards, graficos interativos

Streamlit

APPS

Transforma scripts Python em apps web em minutos. Sem HTML, sem CSS. So Python.

Dashboards, demos, apps de dados

Scikit-learn

ML

Machine Learning simplificado. Classificacao, regressao, clustering. O próximo passo depois de dados.

Predicoes, deteccao de anomalias

Jupyter

NOTEBOOK

Ambiente interativo: escreve codigo, roda, vê resultado e graficos, tudo no mesmo lugar.

Exploracao, analise, documentacao



Projeto 1: Carregando e Explorando Dados

Voce pede: "Instala pandas e matplotlib. Carrega CSV de ataques cibernéticos, mostra primeiras linhas, info e estatísticas."

python

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv("cybersecurity_attacks.csv")

print(df.head())          # 5 primeiras
print(df.shape)           # (linhas, cols)
print(df.info())          # tipos
print(df.describe())      # estatísticas
print(df.columns)         # nomes colunas
print(df.isnull().sum())  # nulos
```

O que você aprende:

<code>import pandas as pd</code>	Importar Pandas
<code>import matplotlib</code>	Importar Matplotlib
<code>pd.read_csv()</code>	Carregar CSV
<code>df.head()</code>	Primeiras linhas
<code>df.shape</code>	Dimensoes
<code>df.info()</code>	Tipos de dados
<code>df.describe()</code>	Estatísticas
<code>df.isnull().sum()</code>	Contar nulos



Projeto 2: Limpando Dados Sujos

Dados reais SEMPRE vem sujos. Limpar e 80% do trabalho!

Voce pede: *"Limpa o dataset: remove duplicados, preenche nulos, convert datas, remove dados invalidos."*

python

```
# Verificar
print(df.isnull().sum())
print(df.duplicated().sum())

# Limpar
df = df.drop_duplicates()
df["tipo"].fillna("desconhecido",
                 inplace=True)
df["data"] = pd.to_datetime(df["data"])
df = df.dropna(subset=["ip_origem"])
```

Conceitos:

<code>.isnull().sum()</code>	Contar nulos
<code>.duplicated()</code>	Achar duplicados
<code>.drop_duplicates()</code>	Remover duplos
<code>.fillna()</code>	Preencher nulos
<code>pd.to_datetime()</code>	Converter data
<code>.dropna()</code>	Remover nulos

🔍 Projeto 3: Filtrando e Agrupando

Voce pede: "Filtra ataques DDoS do ultimo mes, agrupa por país e mostra top 10 com mais ataques."

```
python

ddos = df[df["tipo"] == "DDoS"]

recentes = ddos[ddos["data"] > "2024-01-01"]

por_pais = recentes.groupby("pais_origem")
contagem = por_pais.size()
top10 = contagem.sort_values(
    ascending=False).head(10)

print(top10)
```

Conceitos:

<code>df[condicao]</code>	Filtrar linhas
<code>.groupby()</code>	Agrupar por coluna
<code>.size()</code>	Contar por grupo
<code>.sort_values()</code>	Ordenar
<code>.head(10)</code>	Top 10

Voce pede: "Agora mostra media de duracao dos ataques por pais"

Projeto 4: Graficos com Matplotlib

Agora transformamos os dados em visualizações! Um gráfico conta a história que a tabela esconde.

Voce pede: "Cria 3 graficos: barras top 10 paises, linha ataques por mes, pizza tipos de ataque. Salva PNG."

python

```
import matplotlib.pyplot as plt

# Barras
top10.plot(kind="bar", color="#16C79A")
plt.title("Top 10 Paises - DDoS")
plt.xlabel("Pais")
plt.ylabel("Ataques")
plt.tight_layout()
plt.savefig("top10_ddos.png")
plt.show()
```

Dica pro:

Quer graficos mais bonitos?

Peça pra IA usar Seaborn em vez de Matplotlib puro. Ou Plotly para graficos interativos.

"Refaz esses graficos usando Seaborn com tema dark"

"Agora faz com Plotly interativo"

Iterar = aprender novas ferramentas!



Projeto 5: Analise Completa

Pipeline completo — escolha seu dataset e faça sozinho (com IA!):

1 **Escolher dataset** Kaggle, dados.gov.br ou qualquer fonte que te interesse

2 **Carregar e explorar** `read_csv`, `head`, `shape`, `info`, `describe`

3 **Limpar** Nulos, duplicados, formatos. Dados limpos = confiança

4 **Analisar** Filtrar, agrupar, contar, medias. Responder perguntas

5 **Visualizar** 3+ graficos (Matplotlib ou Seaborn) salvos como PNG

Datasets sugeridos: Cyber Attack (Kaggle, ~50K) | Data Breaches (Kaggle, ~500) | Seguranca BR (dados.gov.br) | COVID-19 Brasil (github/wcota, ~5M) | World Happiness (Kaggle, 150 paises)

Escolha o que te anima! Dados interessantes = motivacao pra aprender.



Salvando no GitHub

repo

kensei-ai-foundations/

semana-01/ ...

semana-02/ ...

semana-03/

01_explorar_dados.py

02_limpar_dados.py

03_filtrar_agrupar.py

04_graficos.py

05_analise_completa.py

graficos/ (PNGs)

README.md

Fluxo:

- 1 Salve tudo (Ctrl+S)
- 2 Stage All > Commit
- 3 "semana 03 - dados pandas"
- 4 Sync Changes (push)
- 5 Inclua os PNGs dos graficos!

Graficos no GitHub aparecem bonitos! Referencie os PNGs no README.md e seu portfolio fica profissional.

✓ Recap + Para Casa

O QUE FIZEMOS

- ✓ Entendemos dados e datasets
- ✓ Conhecemos Pandas e Matplotlib
- ✓ Conhecemos o ecossistema (Seaborn, Plotly...)
- ✓ Carregamos, limpamos e filtrar dados
- ✓ Criamos gráficos profissionais
- ✓ Fizemos análise completa de um dataset

PARA CASA

- ▶ Completar análise de um dataset
- ▶ 3+ gráficos salvos como PNG
- ▶ README com conclusões
- ▶ Push tudo no GitHub
- ▶ Experimentar Seaborn ou Plotly
- ▶ Pesquisar: o que são APIs?

Proxima: Semana 4 — APIs de IA

Vamos conectar Python com APIs de ChatGPT e Claude e criar ferramentas inteligentes!



KENSEI
CYBERSECURITY

```
df = pd.read_csv("minha_vida.csv")
```

```
# agora eu sei ler os dados
```